

Laboratorio de Datos

Trabajo Práctico 01

Grupo “Sanisidrenses”



Guadalupe Cataneo

Máximo Ballestrero

Juana María Leiton

Resumen

El mayor desafío que se nos presentó al desarrollar este trabajo fue tener que tomar decisiones sobre las tablas de datos originales, ya que encontramos muchas deficiencias en la calidad de estas. Sin embargo, conseguimos realizar en conjunto la primera parte del trabajo, considerando lo que pensaba cada integrante del grupo, decidiendo cuáles iban a ser los datos que nos serían útiles para poder determinar el resultado de nuestro objetivo. A partir de esto, dividimos las tareas que requerían ser tratadas, y cada integrante fue desarrollando distintas partes del trabajo. Observamos que no hay relación directa entre la cantidad de habitantes y BP por provincia, pero sí entre la población de los departamentos y los EE que poseen. Finalmente, concluimos que existe una relación débil entre la cantidad de EE y BP por provincia, aunque hallamos que no existe ningún departamento que no tenga EE y sí BP, pero sí existen departamentos que no tienen BP pero sí EE.

Introducción



Para desarrollar este trabajo nos encontramos con una gran cantidad de datos en las BD propuestas. Tuvimos que observar detenidamente cada tabla para entender qué información contenía, cómo relacionarla con todos los datos que necesitábamos para cumplir el objetivo del trabajo, y determinar cuáles eran los datos cuya información no nos sería necesaria para el momento de realizar el análisis de datos que se pide.

Nuestro objetivo era encontrar si existe cierta relación entre la cantidad de establecimientos educativos en cada una de las provincias, y la cantidad de bibliotecas populares. Para ello generamos un DER, que modela de manera conceptual los datos necesarios para resolver los problemas y actividades presentes en el trabajo práctico. Luego definimos los esquemas correspondientes relacionados al modelo relacional de nuestro DER, analizando que todos estén en 3FN.

A partir del modelo relacional comenzamos una limpieza y ordenamiento de datos de las tablas originales, para generar los reportes necesarios utilizando las consultas SQL. Así pudimos identificar la información que nos ayudó a determinar el resultado de nuestro objetivo. A



continuación presentamos el DER propuesto y el modelo relacional correspondiente a este.



Procesamiento de datos

Analizamos las formas normales en que se encuentran las tablas de Establecimientos Educativos y Bibliotecas Populares originales, junto con la calidad de los datos que contienen.

Bibliotecas populares

- 1FN: Cumple la primera forma normal, ya que no posee relaciones dentro de relaciones ó relaciones como valores de atributos dentro de tuplas. Contiene únicamente valores atómicos.
- 2FN: Tomando en cuenta que no existen calles con el mismo nombre dentro de una misma localidad, entonces podemos considerar {cod_localidad, cp, nombre, domicilio} como clave candidata. En ese caso, {id_departamento} depende parcialmente de la clave candidata, pues depende únicamente de {cod_localidad} (observamos que los primeros dígitos del cod_localidad son id_departamento). Luego, no está en 2FN.
- 3FN: Como el esquema no está en 2FN, entonces no cumple 3FN.

Establecimientos educativos

- 1FN: Vemos que en la columna de Teléfono hay valores no atómicos, por lo tanto el esquema no se encuentra en 1FN.
- 2FN y 3FN: Como el esquema no se encuentra en 1FN, entonces tampoco cumple 2FN y 3FN.

Al revisar la calidad de los datos de ambas tablas pudimos identificar:

En el caso de la tabla de Bibliotecas Populares:

- Vimos muchas filas que tenían el campo de mail vacío, esto afecta al atributo de completitud. Consideramos que es un problema de instancia, ya que el problema no proviene de la estructura de la tabla sino de cómo la completaron (probablemente no era campo obligatorio cuando se recolectó).

Para medir la magnitud del problema basándonos en la técnica de GQM consideramos:

- Objetivo (Goal): Que las casillas correspondientes al mail de cada BP tengan el dato completo.



- Pregunta (Question): ¿Cuál es la cantidad de BP que tienen el dato asociado al mail no vacío?
- Métrica (Metric): Tomamos la cantidad de campos no vacíos y la comparamos con el total de registros en la tabla.

Para la métrica propuesta obtuvimos que hay 1022 campos con el mail no vacío, 880 vacías y 1902 en total, queremos comparar los datos completos con la cantidad total de datos registrados, mientras más se acerque la métrica a uno, mejor será la calidad de estos datos. En este caso la métrica devuelve $1022/1902 = 0,53\dots$, lo que nos dice que no hay una buena calidad de información relacionada a la completitud de los mails.

- Pudimos identificar que en el caso de los códigos postales de cada BP, hay campos que no cumplen con el formato que estos deben cumplir (una letra, cuatro números, tres letras). Además hay casillas vacías, esto afecta a los atributos de completitud y corrección. Consideramos que este es un problema de instancia; asumimos que durante la recolección de datos no se estableció un formato predeterminado para los códigos postales, y era opcional ingresarlo.

Para medir la magnitud del problema basándonos en la técnica de GQM consideramos:

- Objetivo (Goal): Que los datos correspondientes al código postal de cada BP se encuentren en el formato correcto y estén completos.
- Pregunta (Question): ¿Cuántas casillas no tienen el formato del código postal correcto ó se encuentran vacías?
- Métrica (Metric): Tomamos la cantidad de registros vacíos y los que tienen código sin letras (los que no cumplen en formato de código postal) para comparar los registros completados de forma correcta (siguiendo el formato) con el total.

En este caso, para la métrica conseguimos que hay 1657 campos con el código sin letras, 4 nulos, 241 con formato correcto y 1902 en total, lo que nos devuelve $241/1902 = 0,12\dots$, esto nos dice que la calidad de los datos es mala en relación con la completitud y la correctitud de los códigos postales.

- Notamos que en las fechas de fundación de las BP la fecha 1980-01-01 se repetía sospechosamente, por lo que tomamos algunas BP al azar con esa fecha para analizar si los datos de ese campo reflejaban la realidad. Al encontrar diversos casos en los que no se cumple la información que se encuentra en la tabla, por ejemplo:



- Bib.Pop. Anastasio Prieto tiene fecha de fundación en 1956-12-08 (dato obtenido en <https://www.ca9dejulio.com/el-club/biblioteca/>)
- Bib.Pop. Maestro Alfredo Bravo tiene fecha de fundación en 2003-05-25 (https://www.acercandonoscultura.com.ar/revista-h-articulo-biblioteca-popular-maestro-alfredo-bravo_342.html#:~:text=Se%20trataba%20del%20maestro%20Alfredo,hij o%20del%20maestro%20Alfredo%20Bravo.)
- Bib.Pop. Angélica R. Nieves tiene fecha de fundación en 1984-08-22 (<https://aniversario150.conabip.gob.ar/bibliotecas/biblioteca-popular-angelica-rosa-nieves-epuyen-chubut/>)

Vimos que se veía afectado el atributo de confiabilidad y de completitud, porque también hay BP que no tienen la fecha de fundación como dato completo. Este es un problema de instancia, seguramente al recolectar los datos se tomó como opción predefinida que la fecha de fundación sea 1980-01-01, hubo BP que lo cambiaron al correcto, otros que decidieron dejarlo vacío y otros que lo dejaron como estaba.

Para medir la magnitud del problema basándonos en la técnica de GQM consideramos:

- Objetivo (Goal): Que estén completas todas las fechas de fundación y su información sea confiable.
- Pregunta (Question): ¿Hay inconsistencias y casillas vacías en los datos registrados?
- Métrica (Metric): Tomamos los casos cuyos campos están vacíos, y los que tienen 1980-01-01 como información.

Para la métrica vimos que hay 40 casillas vacías, 468 con el dato 1980-01-01, 1394 consistentes y 1902 en total, lo que nos devuelve $1394/1902 = 0,73...$, lo que significa que la calidad de los datos es mala en relación a la confiabilidad y completitud de las fechas de fundación.

En el caso de la tabla de Establecimientos Educativos:

- Inconsistencias en los domicilios de los EE, identificamos que hay campos que solo tienen el nombre de la calle o un número, esto afecta al atributo de completitud y es un problema de instancia, consideramos que al tomar los datos no hubo una convención de cómo se debía completar el dato.

Para medir la magnitud del problema basándonos en la técnica de GQM consideramos:

- Objetivo (Goal): Que todos los campos del registro tengan la dirección completa y de manera que se entienda la locación de cada EE.



- Pregunta (Question): ¿Hay casillas que no tienen la información necesaria para localizar el domicilio de los EE?
- Métrica (Metric): Comparamos la cantidad de campos que solo tienen nombre de calle o un número con los que están completos, y luego vemos la proporción de los datos completos que hay en el total del registro.

Para esta métrica conseguimos que hay 82 casillas que solo tienen un número, 916 vacías, 4252 que solo tienen nombre de calle, 58412 con calle y número y 63662 en total, esto nos devuelve $58412/63662 = 0,91\dots$, lo que significa que la calidad de los datos es buena en relación a la completitud de los domicilios de los EE.

- Vimos que en las casillas del mail de cada EE, hay datos que faltan o no coinciden con la estructura de un mail (ej: no tienen el @ en el campo, ó bien son sólo un '@'), esto afecta los atributos de completitud y corrección. Este es un problema de instancia, nosotros asumimos que al recolectar los datos no se tomó como obligación completar la información de los mails, así como tampoco se estableció un formato válido para ingresar.

Para medir la magnitud del problema basándonos en la técnica de GQM consideramos:

- Objetivo (Goal): Que los datos correspondientes a los mails estén completos y sean válidos.
- Pregunta (Question): ¿Cuántos campos están vacíos o contienen un formato inválido?
- Métrica (Metric): Tomamos casillas vacías y las que no cumplen con un formato válido de mail para comparar con el total de registros de los mails en formato válido.

Para esta métrica obtuvimos que hay 188 casillas que tienen un formato inválido, 12173 que están vacías, 51301 que están en un formato válido y en total son 63662, lo que nos devuelve $51301/63662 = 0,80\dots$, lo que significa que la calidad de los datos no es del todo buena en relación a la completitud y corrección de los mails.

- Los campos correspondientes a los códigos de área de los EE tienen valores que no se identifican con el formato que deben tener los códigos de área ó se encuentran vacíos, esto afecta a los atributos de corrección y completitud. Este es un problema de instancia, al tomar los datos no hubo un formato obligatorio para completar la información, y tampoco hubo obligación de hacerlo.

Para medir la magnitud del problema basándonos en la técnica de GQM consideramos:

- Objetivo (Goal): Que los códigos de área se encuentren en el formato correcto y no hayan casillas vacías.

- Pregunta (Question): ¿Cuántos campos poseen el formato correcto y están completos para código de área?
- Métrica (Metric): Tomamos las casillas con números negativos, las que solo tienen ceros, las que están vacías y las que tienen formatos incorrectos.

Para esta métrica obtuvimos que hay 4235 cuyos valores son negativos o cero, 6322 vacías, 107 que no cumplen el formato de código de área, 52998 que están en formato correcto y 63662 en total. Esto nos devuelve $52998/63662 = 0,83\dots$, lo que significa que la calidad de los datos no es tan buena en relación a la corrección y la completitud de los códigos de área.

Decisiones tomadas

- Al recolectar los datos para nuestros esquemas del modelo relacional, unimos la información de todos los departamentos que pertenecen a CABA (comunas), ya que en la tabla de Bibliotecas Populares se representa con un mismo id_Dpto a CABA y no aclara a qué comuna pertenece cada biblioteca. Entonces para cada tabla con la que trabajamos nosotros le asignamos como id_Dpto a CABA el valor 2000, agrupando los datos de cada comuna en un solo departamento.
- Para nuestros esquemas, tomamos jardines infantiles y maternales como Jardín/Nivel Inicial. También consideramos a secundario y secundario INET como Secundario/Nivel Secundario.
- No consideramos el departamento Antártida Argentina (id_Dpto: 94028) para nuestro análisis, si bien figura que hay un colegio ahí según la tabla de EE, no hay información sobre su población en el padrón población. Por lo tanto, no nos sirve ese dato para las consultas.
- En la tabla de población, cambiamos los códigos de área de Ushuaia y Río Grande de 94008 a 94007 y de 94015 a 94014 (respectivamente), pues así logramos que id_Dpto coincida con las otras dos tablas originales.
- Notamos que el departamento de Chascomús tenía id de departamento distinto en las tablas. En Población y EE, tenía el id 06218. Mientras que en BP figura con 06217. Tomamos la decisión de cambiar en BP el id a 06218, ya que era el único id diferente.

Análisis de datos

Reporte i)

Para cada departamento informamos su id, provincia, nombre, la cantidad de EE de cada nivel educativo, considerando solamente la modalidad común, y cantidad de habitantes por edad según los niveles educativos.

Provincia	Departamento	Jardines	Población Jardines	Primarias	Población Primaria	Secundarios	Población Secundaria
Buenos Aires	La Matanza	325	157034	333	193043	335	214041
Buenos Aires	La plata	232	52075	199	66893	206	78431
Buenos Aires	Lomas de Zamoras	162	50825	178	65571	191	76653
Buenos Aires	General Pueyrredón	178	41427	169	53294	170	67001
...	...	...	...	...	...	...	...

Reporte ii)

Para cada departamento informamos su id, provincia, nombre y cantidad de BP fundadas desde 1950.

Provincia	Departamento	Cantidad de BP fundadas desde 1950
Buenos Aires	La Matanza	15
Buenos Aires	La Plata	15
Buenos Aires	Moreno	13
Buenos Aires	Bahía Blanca	12
...	...	...

Reporte iii)

Para cada departamento indicamos su id, provincia, nombre, cantidad de BP, cantidad de EE (de modalidad común) y población total.

Provincia	Departamento	Cant_EE	Cant_BP	Población
Ciudad de Buenos Aires	Ciudad de Buenos Aires	1567	43	3095454
Córdoba	Capital	1054	20	1498060
Buenos Aires	La Matanza	957	16	1837168
Santa FE	Rosario	742	39	1337958.0
...	...	...	...	...

Reporte iv)

Para cada departamento indicamos su id, provincia, nombre y qué dominios de mail se usan más para las BP

Provincia	Departamento	Dominio más frecuente
Santa Fe	Caseros	gmail
Buenos Aires	Bahía Blanca	yahoo
San Luis	Coronel Pringles	hotmail
Buenos Aires	Hurlingham	yahoo
...	...	...


Gráficos:

i)

Utilizando los datos obtenidos a partir del reporte (iii), mostramos la cantidad de BP por provincia, observamos que CABA es la provincia con mayor cantidad de BP, lo cual consideramos llamativo, ya que Buenos Aires es la provincia con mayor cantidad de población y se encuentra




cuarto en cantidad de BP entre todas las provincias. Sin hacer un análisis puntual, se ve que no hay una relación entre la cantidad de habitantes por provincia y la cantidad de BP.




ii)

A partir del primer reporte que generamos, graficamos la cantidad de EE en función de la población por nivel educativo. Para la población entre 0 y 75000 habitantes, vemos que hay una cantidad de EE similar para la población de los tres niveles educativos, entre 0 y 200. Para la población entre 75000 y 250000 no se ve un comportamiento para la cantidad de EE, hay mayor cantidad de establecimientos para habitantes en edad de Jardín y Primario, aunque la población más grande sea en edad de Secundario.




iii)



Notamos que Buenos Aires tiene una gran cantidad de *outliers*. Suponemos que esto sucede por el desbalance demográfico en la provincia; es decir, que hay unos pocos departamentos con mucha población (y por lo tanto, establecimientos educativos), pero la mayoría tienen menor población. Entonces, la mediana y la media se ven afectadas por la mayoría de los valores, que son más bajos. Luego, los departamentos con alta cantidad de EE son los outliers.

Por otro lado, notamos que Ciudad de Buenos Aires representa un sólo valor, esto se debe a que agrupamos todos sus departamentos como uno. Esto genera que no se vea representada ninguna distribución, solamente se ve plasmado el único valor de cantidad de EE por ese departamento. Además, al ser solo 1 valor, todos los cuartiles, la media y la mediana.

iv)



A partir de la información del reporte 3, calculamos la cantidad de Bibliotecas Populares y Establecimientos Educativos cada 1000 habitantes, para cada departamento. Cada punto del gráfico representa un departamento. Notamos que no existe ningún departamento que no tenga EE pero si BP. Sin embargo, sí existen departamentos que no tienen BP pero si EE. Además, vemos que la mayoría de los departamentos tienen entre 0 y 4 establecimientos educativos por 1000 habitantes, y entre 0 y 0.5 BP por 1000 habitantes.

Anexo:

Primer reporte: [reporte1](#)

Segundo reporte: [reporte2](#)


Tercer reporte: [reporte3](#)

Cuarto reporte: [reporte4](#)

Conclusiones

Dado que no habíamos analizado la característica de ámbito y sector en la BD de EE, nos planteamos investigar la relación entre ellas, si es que existe, a nivel departamento. Tomamos, en ambos casos, la relación entre BP/EE cada mil habitantes, discriminando entre EE estatales y EE privados. Nuestros gráficos y conclusiones son los siguientes:


Relación entre cantidad de BP y EE cada 1000 habitantes por departamento



En este primer gráfico donde podemos observar la relación entre BP cada 1000 habitantes y EE cada 1000 habitantes, distinguiendo aquellos que son estatales de los privados, podemos observar una clara separación. Esto se debe a que los departamentos tienen una mayor cantidad de EE estatales que privados (cada 1000 habitantes). Además, podemos agregar la observación de que mientras que sí hay departamentos que no tienen EE privados pero sí BP, no hay departamentos sin EE estatales pero con BP.



Relación entre cantidad de BP y EE cada 1000 habitantes por departamento



En este segundo gráfico, podemos observar la relación entre BP y EE cada 1000 habitantes, distinguiendo aquellos que son rurales de los urbanos. Notemos que la separación no es tan obvia. Hay departamentos con BP y sin EE, para ambas categorías de EE. Principalmente vemos que hay más EE rurales que urbanos por departamento (cada 1000 habitantes).

En conclusión, tras analizar varios aspectos, notamos que la relación entre la cantidad de EE y BP por provincia es débil. Si bien, considerando los gráficos y análisis presentados, no hallamos ninguna tendencia marcada, rescatamos que en todos los departamentos, no hay BP sin EE, en particular los estatales.